

Hadoop 伪分布式部署

前置条件：请在完成 [5.安装openssh-server](#) 和 [6.安装并配置Java](#) 之后，再来完成本文档的内容。

实验必备：理解 Hadoop 伪分布式模式

伪分布式模式 (Pseudo-Distributed Mode) 是学习 Hadoop 的最佳起点。它在单台机器上模拟分布式环境，所有守护进程 (NameNode、DataNode、ResourceManager、NodeManager) 都运行在同一节点上。

1. 为什么选择伪分布式？


- **学习成本低：**无需多台物理机器，一台虚拟机即可体验完整的 Hadoop 功能
- **资源消耗适中：**相比完全分布式，资源占用更少
- **功能完整：**支持 HDFS 和 YARN 的所有核心功能，适合开发和测试


2. Hadoop 核心进程解析

进程名称	角色定位	功能描述
NameNode	HDFS 管家	管理文件系统的元数据（文件名、目录结构、文件位置等）
DataNode	HDFS 仓库	实际存储数据块，负责数据的读写操作
SecondaryNameNode	NameNode 助手	定期合并 NameNode 的镜像文件和日志，减轻其负担
ResourceManager	YARN 调度中心	负责集群资源的分配和任务调度
NodeManager	单节点资源管理者	管理单台机器的 CPU、内存等资源，执行具体任务

步骤 1：上传 Hadoop 安装包

用 WinSCP 连接 Ubuntu 24 虚拟机，将 Hadoop 3.3.6 的压缩包和安装脚本 `install_hadoop.sh` 传到用户目录的 Downloads 目录下。





步骤 2：执行安装脚本

打开终端，运行如下指令安装并伪分布式部署 Hadoop：

```
cd ~/Downloads/  
chmod +x install_hadoop.sh  
./install_hadoop.sh
```

```
hadoop@hadoop: ~/Downloads

hadoop@hadoop:~/Desktop$ cd ~/Downloads/
hadoop@hadoop:~/Downloads$ chmod +x install_hadoop.sh
hadoop@hadoop:~/Downloads$ ./install_hadoop.sh
=== Hadoop 3.x 伪分布式一键部署工具 ===
[检查通过] 检测到安装包: hadoop-3.3.6.tar.gz
正在清理并准备安装目录: /usr/local/hadoop
[sudo] hadoop 的密码:
正在解压并剥离首层文件夹 (strip-components=1)...
[验证成功] 安装目录已创建: /usr/local/hadoop
[验证成功] 检测到配置目录: /usr/local/hadoop/etc/hadoop
权限已修正, 当前用户 hadoop 拥有该目录权限。
正在配置系统环境变量 (~/.bashrc)...
[配置成功] HADOOP_HOME 已加入 ~/.bashrc
正在配置 hadoop-env.sh...
正在生成 XML 配置文件...
正在创建数据目录并格式化 NameNode...
[成功] HDFS 格式化完成!

=====
hadoop 伪分布式部署成功完成!

. 激活环境: source ~/.bashrc
. 启动集群: start-dfs.sh 接着 start-yarn.sh
. 验证进程: jps
. 管理页面: http://localhost:9870
```

步骤 3：启动 Hadoop 并验证

关闭当前终端，再打开一个终端，然后按顺序输入指令启动 Hadoop，先启动 HDFS，后启动 YARN，接着输入 `jps` 指令，如果能看到 NameNode、DataNode、SecondaryNameNode、ResourceManager 和 NodeManager 5 个进程，说明 Hadoop 伪分布式部署成功并成功启动。

💡 小贴士：jps 是什么？

`jps` 是 Java Process Status Tool 的缩写，是 JDK 自带的工具，用于列出当前系统中所有正在运行的 Java 进程。

```
start-dfs.sh
start-yarn.sh
jps
```

```
hadoop@hadoop: ~/Desktop
hadoop@hadoop:~/Desktop$ start-dfs.sh
Starting namenodes on [localhost]
Starting datanodes
Starting secondary namenodes [hadoop]
hadoop: Warning: Permanently added 'hadoop' (ED25519) to the list of known hosts
.
hadoop@hadoop:~/Desktop$ start-yarn.sh
Starting resourcemanager
Starting nodemanagers
hadoop@hadoop:~/Desktop$ jps
4386 DataNode
4917 NodeManager
4779 ResourceManager
4220 NameNode
4589 SecondaryNameNode
5247 Jps
hadoop@hadoop:~/Desktop$
```

步骤 4: 访问 HDFS 文件管理页面

打开虚拟机上的火狐浏览器，输入 `http://localhost:9870/` 访问 HDFS 文件管理页面。

HDFS 文件管理页面 (端口: 9870)

- **访问地址：** `http://localhost:9870`
- **对应进程：** NameNode
- **它的作用（仓库管理员）：**
 - **集群健康概览：** 查看 DataNode 是否在线、磁盘空间占了多少、有没有损坏的数据块（Corrupt Blocks）。
 - **浏览文件系统 (Utilities -> Browse the file system)：** 可以像用 Windows 资源管理器一样，直观地看到 `/resume_matching/raw_data/` 下面有没有刚才上传的 CSV 文件。
 - **下载文件：** 甚至可以直接在网页上把 HDFS 里的清洗结果下载到本地查看。

5月28日 16 : 13

zh

All Applications x Namenode information x +

← → ↻

🔒 http://localhost:9870/dfshealth.html#tab-overview

🔍 ☆

👤 📄 ☰

Hadoop Overview Datanodes Datanode Volume Failures Snapshot Startup Progress Utilities ▾

Overview 'localhost:9000' (✔active)

Started:	Thu May 28 14:15:59 +0800 2026
Version:	3.3.6, r1be78238728da9266a4f88195058f08fd012bf9c
Compiled:	Sun Jun 18 16:22:00 +0800 2023 by ubuntu from (HEAD detached at release-3.3.6-RC1)
Cluster ID:	CID-36ced3b7-e364-4679-b780-54029542db34
Block Pool ID:	BP-1996962333-127.0.1.1-1779948881198

Summary

Security is off.

Safemode is off.

1 files and directories, 0 blocks (0 replicated blocks, 0 erasure coded block groups) = 1 total filesystem object(s).

Heap Memory used 175.74 MB of 301 MB Heap Memory. Max Heap Memory is 1.71 GB.

Non Heap Memory used 63.38 MB of 64.86 MB Committed Non Heap Memory. Max Non Heap Memory is <unbounded>.

Configured Capacity:	39.07 GB
Configured Remote Capacity:	0 B
DFS Used:	28 KB (0%)
Non DFS Used:	13.58 GB
DFS Remaining:	23.48 GB (60.08%)
Block Pool Used:	28 KB (0%)
DataNodes usages% (Min/Median/Max/stdDev):	0.00% / 0.00% / 0.00% / 0.00%
Live Nodes	1 (Decommissioned: 0, In Maintenance: 0)
Dead Nodes	0 (Decommissioned: 0, In Maintenance: 0)
Decommissioning Nodes	0
Entering Maintenance Nodes	0
Total Datanode Volume Failures	0 (0 B)
Number of Under-Replicated Blocks	0

步骤 5：访问 YARN 资源管理页面

输入 `http://localhost:8088/` 访问 YARN 资源管理页面。

YARN 资源管理页面 (端口: 8088)

- **访问地址:** `http://localhost:8088`
- **对应进程:** ResourceManager
- **它的作用 (调度大总管) :**
 - **监控资源使用:** 实时显示整个集群还有多少 CPU 核心 (VCores) 和内存 (Memory) 可用。
 - **管理计算任务:** 当运行 PySpark 脚本或 MapReduce 任务时, 所有的任务都会出现在这个列表里。
 - **状态追踪:** 你可以看到任务是“正在运行 (RUNNING)”、“成功 (SUCCEEDED)”还是“失败 (FAILED)”。
 - **查看日志 (核心排错点) :** 如果程序报错了, 点进任务的 Logs, 能看到最详细的报错堆栈。

5月28日 16 : 15

zh

All Applications x Namenode information x +

← → ↻

🔒 http://localhost:8088/cluster

🔍 ☆



Cluster

About

Nodes

Node Labels

Applications

NEW

NEW_SAVING

SUBMITTED

ACCEPTED

RUNNING

FINISHED

FAILED

KILLED

Scheduler

Tools

All Applications

Cluster Metrics

Apps Submitted	Apps Pending	Apps Running	Apps Completed	Containers Running	Used Resources	Total Resources	Reserved Resources
0	0	0	0	0	<memory:0 B, vCores:0>	<memory:8 GB, vCores:8>	<memory:0 B, vCores:0> 57

Cluster Nodes Metrics

Active Nodes	Decommissioning Nodes	Decommissioned Nodes	Lost Nodes	Unhealthy Nodes	Reboot
1	0	0	0	0	0

Scheduler Metrics

Scheduler Type	Scheduling Resource Type	Minimum Allocation	Maximum Allocation	Maximum Cluster Application
Capacity Scheduler	[memory-mb (unit=Mi), vcores]	<memory:1024, vCores:1>	<memory:8192, vCores:4>	0

Show 20 entries

ID	User	Name	Application Type	Application Tags	Queue	Application Priority	StartTime	LaunchTime	FinishTime	State	FinalStatus	Running Containers	Allocated CPU VCores	Allocated Memory MB	Allocated GPUs	Reserved CPU VCores	Reserved Memory MB	Reserved GPUs
No data available in table																		

Showing 0 to 0 of 0 entries

步骤 6：关闭 Hadoop

关闭火狐浏览器，输入指令关闭 Hadoop。**必须严格按照此顺序关闭**：先停止资源调度框架 (YARN)，再停止分布式文件系统 (HDFS)。关闭之后用 `jps` 查看，**确保看不到任何 Hadoop 相关的进程才算关闭成功**。一切完成之后，请关闭虚拟机并**拍摄快照**。

为什么要先关 YARN? YARN 是负责跑任务的“管理者”。先关闭它，可以确保当前没有正在运行的计算任务在尝试读写数据，避免数据写入中途被强行中断。关闭后，`ResourceManager` 和 `NodeManager` 进程会消失。

为什么要后关 HDFS? HDFS 是“仓库”。等所有的工人（计算任务）都下班了，我们再锁上仓库大门。这一步会安全地保存元数据（NameNode 的状态）。关闭后，`NameNode`、`DataNode` 和 `SecondaryNameNode` 进程会消失。

```
stop-yarn.sh
stop-dfs.sh
jps
```

```
hadoop@hadoop:~/Desktop$ stop-yarn.sh
Stopping nodemanagers
Stopping resourcemanager
hadoop@hadoop:~/Desktop$ stop-dfs.sh
Stopping namenodes on [localhost]
Stopping datanodes
Stopping secondary namenodes [hadoop]
hadoop@hadoop:~/Desktop$ jps
7909 Jps
hadoop@hadoop:~/Desktop$
```